

为实现多无人机在复杂环境下的协同搜索，可以在障碍物环境下实现高效覆盖任务区域的同时对目标进行搜索，通过对搜索任务建立优化模型，引导学习实现端到端的策略学习，建立顶层任务分配实现高效搜索目标，系统架构如图 1 所示。本项目涉及的研究方法如下：




图 1 系统架构

(1) 基于滚动时域规划框架的协同搜索环境建模

根据协同搜索目标的任务设定，本文将任务环境模型进行简化，任务区域 Ω 设定为划分成 $L_x \times L_y$ 的网格的矩形区域。在这个任务空间中，假设有 N_U 个同质无人机在固定高度执行搜索任务，如图 2 所示。为了保证机器人的运动平滑（位置连续、速度连续、加速度连续），我们使用五次多项式来表示轨迹， $\mu \in \{x, y\}$ ：

$$f_{\mu}(t) = a_0 + a_1 t + a_2 t^2 + a_3 t^3 + \dots + a_n t^n \quad (1)$$

系数的向量写为：

$$\mathbf{A} = [a_0, a_1, a_2, a_3, \dots, a_n] \quad (2)$$

每条轨迹由其多项式系数向量 $\mathbf{A} \in \mathbb{R}^{12}$ （包含 x 和 y 轴各 6 个系数）唯一确定。利用已知的一组起始状态 d_F （来自状态估计）和网络预测的末端状态 d_P ，我们构建两点边界值问题(Boundary Value Problem, BVP)的边界条件向量：

$$\mathbf{d} = [\mathbf{p}_F, \mathbf{v}_F, \mathbf{a}_F, \mathbf{p}_P, \mathbf{v}_P, \mathbf{a}_P]^T \quad (3)$$

多项式系数 $\mathbf{A}$ 与边界条件 $\mathbf{d}$ 之间存在线性映射关系：

$$\mathbf{A} = \mathbf{M}^{-1} \mathbf{d} \quad (4)$$

$$\mathbf{A} = \mathbf{M}^{-1} \mathbf{C} \begin{bmatrix} \mathbf{d}_F \\ \mathbf{d}_P \end{bmatrix} \quad (5)$$

其中， $\mathbf{M}$ 是仅与规划时间 T 有关的映射矩阵， C 是转换矩阵。




图 2 多无人机协同搜索任务模型

由于解空间比较大，本文采用一组运动基元 $\mathcal{P} = \{p_0, p_1, p_2, \dots, p_{N_\phi}\}$ 作为锚点覆盖搜索空间，每个基元指导训练中的独立优化。如图 3 所示，本文将无人机的视场角均匀的切分成 N_ϕ 个方向，运动基元在机体坐标系下的表示为：

$$\mathbf{p}_i = (r \cos \varphi_i, r \sin \varphi_i) \quad (6)$$

其中， r 是规划半径， $i \in [1, N_\phi]$ 。

对于每个运动基元，通过神经网络预测偏移量 $\Delta\varphi$ 和 Δr ，以及末端导数（速度和加速度）和相应的分数，可以得到末端状态的运动基元：

$$\mathbf{p}'_i = (r'_i \cos \varphi'_i, r'_i \sin \varphi'_i) \quad (7)$$

其中， $\varphi'_i = \varphi + \Delta\varphi_i$ ， $r'_i = r + \Delta r_i$ 。




图 3 无人机的运动基元和末端基元

每架无人机底部都安装了一个传感器用以检测目标, 传感器的覆盖范围是半径为 R_s 的圆, A_i 是无人机的探测区域, 传感器的检测概率和虚警概率分别为 $P_D \in (0,1)$ 和 $P_F \in (0,1)$, 并使用贝叶斯概率更新目标存在概率:

$$p(x, y, t+1) = \begin{cases} \frac{P_D p(x, y, t)}{P_F + (P_D - P_F) p(x, y, t)}, & \zeta = 1 \\ \frac{(1 - P_D) p(x, y, t)}{1 - P_D p(x, y, t) - P_F (1 - p(x, y, t))}, & \zeta = 0 \end{cases} \quad (8)$$

其中, $p(x, y, t)$ 是时间位置 (x, y) 和时间 t 时刻的目标存在概率, ζ 表示无人机独立确定网格中是否存在目标的情况, $\zeta = 1$ 目标存在。

无人机在搜索目标的同时需要尽可能覆盖整个任务区域, 设定环境不确定性 $\chi(x, y, t)$, 检测前为 1, 检测后 $\chi(x, y, t) = 0.5\chi(x, y, t)$ 。

无人机 i 在时刻 k 的基于当前状态和环境观测, 利用神经网络在预测时域 T 内生成一组参数化的候选轨迹簇 $\mathcal{T}_i(k)$:

$$\mathcal{T}_i(k) = \{\tau_{i,n}(t) | n=1, 2, \dots, N_\phi\} \quad (9)$$

$$\tau_{i,n}(t) = \text{Poly}(A_n, t), \quad t \in [0, T] \quad (10)$$

无人机采用滚动时域优化进行分布式自主决策，每个无人机共享其在通信网络中的状态、动作和搜索结果。在每个决策周期中，无人机根据所获得的信息在所有预测动作序列中搜索最优解。无人机 i 的协同搜索决策模型可以表示为：

$$\begin{aligned} \tau_i^*(k) = \operatorname{argmax}_{\tau_{i,n} \in \mathcal{T}_i(k)} \hat{J}_{\text{score}}(\tau_{i,n} | s_i(k), O_{-i}(k)) \\ \text{s.t.} \begin{cases} \tau_{i,n}(t) = \text{Poly}(A_n, t) \\ \tau_{i,n}(0) = s_i(k) \\ \|\dot{\tau}_{i,n}(T)\| \leq v_{\max}, \quad \|\ddot{\tau}_{i,n}(T)\| \leq a_{\max} \\ n \in \{0, 1, 2, \dots, N_\phi\}, \quad i \in \{1, 2, \dots, N_U\}, \quad t \in [0, T] \end{cases} \end{aligned} \quad (11)$$

其中， $O_{-i}(k)$ 表示除无人机 i 之外的其他无人机在时间 k 的共享信息。 $\tau_i^*(k)$ 表示优化问题求解的最优轨迹。

可行性：本项目基于滚动时域规划框架建立多无人机协同搜索的任务模型，将多无人机协同搜索问题的全周期优化问题转化为短周期的优化问题，符合多无人机不断探索不断接近目标的实时求解过程，为后续引入引导学习奠定了基础。

(2) 基于引导学习的协同搜索策略

由于实际搜索任务环境的复杂性，多无人机对协同路径规划能力要求愈发提高。本项目提出一种基于引导学习的协同搜索策略，旨在通过引导学习将离散运动模型改进为连续运动模型，满足复杂环境下的路径规划，并降低学习训练量。

引导学习是一种创新的无监督训练策略，旨在利用环境物理场的数值梯度直接指导神经网络生成最优轨迹，从而克服模仿学习对专家质量的依赖及强化学习收敛困难的问题。该方法在训练阶段引入“特权学习”机制，利用全局完美的环境信息（如障碍物 ESDF 或搜索概率图）构建包含平滑性、安全性及任务收益的连续可微代价函数。通过计算这些代价函数关于轨迹参数的梯度，并利用链式法则将其直接反向传播至网络权重，引导学习使网络能够内化环境约束与动力学特性，最终在推理阶段仅凭局部受限观测即可通过单次前向传播快速生成高质量、无碰撞且满足动力学约束的连续多项式轨迹。

本文中，通过神经网络预测输出 y ，其中包含偏移量 $\Delta\varphi$ 和 Δr ，以及末端导数（速度和加速度）和相应的分数，可以得到末端状态的运动基元，网络架构如图 4 所示。




图 4 引导学习网络架构

为了训练网络在无专家演示的情况下学会高效搜索与协同，本文构建了一个基于物理场的引导损失函数 J_g ，该函数将环境地图的数值梯度直接反向传播给网络。总损失函数定义为：

$$\mathcal{L}_t = \mathcal{L}_s(y_s, -J_g) + \lambda_g J_g \quad (12)$$

其中， $\mathcal{L}_s$ 为监督网络评分预测的 Smooth-L1 损失， J_g 由以下四部分组成：

$$J_g = \omega_1 J_{\text{search}} + \omega_2 J_{\text{coop}} + \omega_3 J_{\text{safe}} + \omega_4 J_{\text{smooth}} \quad (13)$$

a) 引导搜索项 J_{search}

引导无人机最大化对目标存在概率密度函数（PDF）的采样，并根据信息熵动态调整搜索速度：

$$J_{\text{search}}(\mathbf{A}) = -\sum_{k=1}^K [\alpha \cdot \mathcal{M}_p(\mathbf{p}(t_k)) + \beta \cdot \mathcal{M}_v(\mathbf{p}(t_k))] \Delta t \quad (14)$$

其中， $\mathcal{M}_p(p)$ 和 $\mathcal{M}_v$ 分别是通过双线性插值（Bilinear Interpolation）从网格中获取位置 p 处的概率值和不确定性值。

b) 协同项

为了在预测时域内实现隐式协同与防碰撞，引入基于高斯函数的动态排斥势场。对于通信范围内邻居集合 $\mathcal{N}_j$ 中的每一邻居 j ，计算其预测轨迹 $\tau_j^*(t)$ 与自身轨迹的距离代价：

$$J_{\text{coop}} = \sum_{j \in \mathcal{N}_i} \sum_{k=1}^K \exp \left(-\frac{\|\mathbf{p}_i(t_k) - \mathbf{p}_j(t_k)\|^2}{2\sigma_{\text{safe}}^2} \right) \Delta t \quad (15)$$

其中， $\mathbf{p}_j$ 是邻居 j 在同一时刻 t 的预测位置， σ_{safe} 是排斥势场的有效安全距离。

c) 避障项

为避免与障碍物发生碰撞，引入避障势能：

$$J_{\text{coll}}(\mathbf{A}) = \sum_{k=1}^K \mathcal{C}_{\text{obs}}(\mathbf{p}(t_k)) \Delta t \quad (16)$$

$$\mathcal{C}_{\text{obs}}(\mathbf{p}) = \max(0, D_{\text{safe}} - d(\mathbf{p}))^2 \quad (17)$$

其中， $d(\mathbf{p})$ 是与障碍物之间的距离。

d) 动力学平滑项

为了确保生成的轨迹满足动力学约束，采用 Minimum Jerk 准则，即最小化加加速度的积分：

$$J_{\text{smooth}} = \int_0^T \left\| \ddot{\mathbf{p}}(t) \right\|^2 dt \quad (18)$$

$$J_{\text{smooth}} = \mathbf{A}^T \mathbf{Q} \mathbf{A} \quad (19)$$

其中， $\mathbf{Q}$ 为常数矩阵。

利用 $\mathbf{A} = \mathbf{M}(T)^{-1} \mathbf{d}$ ：

$$J_{smooth} = \begin{bmatrix} \mathbf{d}_F \\ \mathbf{d}_P \end{bmatrix}^T \begin{bmatrix} \mathbf{B}_{FF} & \mathbf{B}_{FP} \\ \mathbf{B}_{PF} & \mathbf{B}_{PP} \end{bmatrix} \begin{bmatrix} \mathbf{d}_F \\ \mathbf{d}_P \end{bmatrix} \quad (20)$$

其中， $\mathbf{B} = \mathbf{C}^T \mathbf{M}^{-T} \mathbf{Q} \mathbf{M}^{-1} \mathbf{C}$ 。

为了实现策略网络的端到端训练，我们需要计算引导损失函数 J_g 关于末端状态的梯度：

$$\frac{\partial J_g}{\partial \mathbf{d}_p} = \lambda_{search} \frac{\partial J_{search}}{\partial \mathbf{d}_p} + \lambda_{coop} \frac{\partial J_{coop}}{\partial \mathbf{d}_p} + \lambda_{coll} \frac{\partial J_{coll}}{\partial \mathbf{d}_p} + \lambda_{smooth} \frac{\partial J_{smooth}}{\partial \mathbf{d}_p} \quad (21)$$

网络预测的梯度可以表示为：

$$\frac{\partial J_g}{\partial y_\varphi} = \frac{\partial J_g}{\partial \mathbf{d}_p} \frac{\partial \mathbf{d}_p}{\Delta \varphi} \frac{\Delta \varphi}{\partial y_\varphi} \quad (22)$$

$$\frac{\partial J_g}{\partial y_\varepsilon} = \frac{\partial J_g}{\partial \mathbf{d}_p} \frac{\partial \mathbf{d}_p}{\partial y_\varepsilon} \quad (23)$$

其中， $\varepsilon \in \{v, a\}$ 。

可行性：本方案的可行性建立在物理场的可微性与轨迹的解析性基础之上。首先，通过构建连续可微的物理引导函数（涵盖搜索收益与障碍势场），将离散的环境约束转化为明确的数值梯度，利用反向传播机制直接驱动策略网络参数的更新，从而在无专家标注的条件下实现高效、收敛的端到端训练。其次，采用时间参数化的多项式作为输出表征，天然保证了轨迹的高阶连续性（位置、速度、加速度连续），从运动学底层确保了无人机在密集障碍物环境下的敏捷避障能力与飞行稳定性。